

UNIVERSIDADE FEDERAL DE MINAS GERAIS

**CARACTERIZAÇÃO E EXTRAÇÃO DE ATRIBUTOS DE
FALTAS DE ALTA IMPEDÂNCIA EM VEGETAÇÃO:
APLICAÇÃO EM DADOS REAIS**

ANDRÉ VERSIANI DE MATTOS

Belo Horizonte - Minas Gerais, 2026

ANDRÉ VERSIANI DE MATTOS

**CARACTERIZAÇÃO E EXTRAÇÃO DE ATRIBUTOS DE FALTAS DE
ALTA IMPEDÂNCIA EM VEGETAÇÃO: APLICAÇÃO EM DADOS REAIS**

Trabalho de Conclusão de Curso apresentado
junto ao programa de **Graduação em
Engenharia de Sistemas** do **Universidade
Federal de Minas Gerais**, como requisito
parcial à obtenção do título de **Bacharel em
Engenharia de Sistemas**.

Orientadora:

Prof.^a Dra. Gabriela Nunes Lopes.

Belo Horizonte - Minas Gerais, 2026

SUMÁRIO

1	INTRODUÇÃO	1
2	REVISÃO DA LITERATURA	3
2.1	Faltas de Alta Impedância	3
2.2	Métodos de Detecção de FAIs	4
2.3	Técnicas de Processamento de Sinais	5
2.4	Algoritmos de Inteligência Artificial	7
3	METODOLOGIA	10
3.1	Base de dados e origem dos registros reais	10
3.2	Definição do problema e das classes	11
3.3	Pré-processamento e preparação dos sinais	11
3.4	Extração de atributos e caracterização das FAIs em vegetação	12
3.4.1	Atributos no domínio do tempo	12
3.4.2	Atributos no domínio da frequência	13
3.4.3	Atributos no domínio tempo-frequência	14
3.5	Seleção de atributos	14
3.6	Classificadores supervisionados	15
3.7	Métricas de avaliação e análise de desempenho	16
	REFERÊNCIAS	18

1 INTRODUÇÃO

A energia elétrica constitui um insumo essencial para o funcionamento da sociedade contemporânea, sustentando atividades produtivas, serviços públicos e aplicações críticas em áreas como saúde, comunicação e infraestrutura. Nos sistemas de distribuição, a continuidade do fornecimento e a confiabilidade da operação dependem da capacidade de identificar perturbações que, embora nem sempre apresentem correntes elevadas, podem comprometer a segurança e a integridade da rede ([International Energy Agency, 2020](#)).

Nesse contexto, as faltas de alta impedância (FAIs) são reconhecidas, desde os trabalhos clássicos da década de 1980, como um dos problemas mais persistentes e difíceis enfrentados pela proteção de sistemas elétricos ([AUCOIN; RUSSELL, 1982](#); [WESTER, 1998](#)). Essas ocorrências foram descritas como situações em que um condutor energizado entra em contato com meios de alta resistência, como solo seco, asfalto ou outros materiais semelhantes, produzindo correntes insuficientes para a atuação confiável das proteções convencionais por sobrecorrente. ([AUCOIN; JONES, 1996](#)). Além disso, a literatura demonstra que as FAIs apresentam características complexas, com comportamento não linear, assimetria e assinaturas dependentes das condições de contato e do ambiente, o que dificulta sua detecção e localização ([NAM et al., 2001](#); [SHENG; ROVNYAK, 2004](#)).

Com o avanço das pesquisas a partir dos anos 2000, diferentes métodos passaram a ser propostos para melhorar a identificação dessas ocorrências, incluindo abordagens baseadas em componentes de alta frequência, harmônicos, inter-harmônicos e análise no domínio do tempo e da frequência ([SHENG; ROVNYAK, 2004](#); [SANTOS et al., 2017](#); [LIMA et al., 2018](#); [GOMES et al., 2018](#)). Esses estudos indicam que, embora haja progresso na modelagem e na detecção, o problema permanece relevante para a engenharia de proteção, sobretudo quando se consideram as variações reais do sistema e as dificuldades de implementação em campo ([SANTOS et al., 2017](#); [LIMA et al., 2018](#)).

Quando associadas à vegetação, as FAIs assumem importância ainda maior, pois podem prolongar a ocorrência de arco elétrico e aumentar o risco de ignição de materiais combustíveis. A literatura recente destaca que as faltas relacionadas à vegetação podem causar danos à rede, dificuldades operacionais e até incêndios, o que as torna particularmente críticas em áreas com arborização próxima às linhas aéreas ([GOMES et al., 2018](#); [YANG et al., 2025](#)).

Os dados registrados durante FAIs utilizados neste trabalho ([Victorian Government, 2014](#)) foram obtidos a partir do programa experimental Vegetation Conduction

Ignition Test Program, desenvolvido no âmbito do Powerline Bushfire Safety Program do governo de Victoria, após os incêndios florestais de 2009. Esse programa foi criado para aprofundar o entendimento dos processos de ignição em faltas envolvendo vegetação e para estabelecer uma base de referência de assinaturas elétricas de falha, com o objetivo de apoiar o desenvolvimento de métodos mais eficientes de detecção. O conjunto de dados é especialmente relevante porque contém registros reais de testes controlados, com múltiplas espécies vegetais, diferentes condições experimentais e sinais elétricos capturados em alta resolução, o que o torna adequado para a formulação de um problema de classificação.

Diante do exposto, o presente estudo tem como objetivo caracterizar faltas de alta impedância associadas à vegetação a partir de registros reais, com ênfase na extração de atributos relevantes das medições realizadas. Esses atributos serão analisados quanto ao seu poder discriminativo e utilizados como base para a construção de um problema de classificação capaz de distinguir, de forma sistemática, eventos de falta.

2 REVISÃO DA LITERATURA

2.1 FALTAS DE ALTA IMPEDÂNCIA

As faltas de alta impedância (FAIs) constituem um dos problemas mais persistentes e difíceis enfrentados pela proteção de sistemas elétricos de distribuição ([WESTER, 1998](#); [AUCOIN; JONES, 1996](#)). Caracterizam-se pelo contato não intencional entre um condutor energizado e um meio de elevada resistência elétrica como solo seco, asfalto, concreto, grama ou vegetação resultando em correntes de falta de baixa magnitude, tipicamente na faixa de 0 a 85 A, insuficientes para acionar as proteções convencionais por sobrecorrente, como fusíveis e relés de sobrecorrente ([AUCOIN; RUSSELL, 1982](#); [ALJOHANI; HABIBALLAH, 2020](#)).

Ao contrário das faltas de baixa impedância, que envolvem correntes elevadas e são detectadas com facilidade pelas proteções tradicionais, as FAIs não representam risco imediato de danos ao equipamento elétrico. Contudo, o condutor permanece energizado, configurando sério risco à segurança pública e potencial de ignição de incêndios ([AUCOIN; JONES, 1996](#); [SEDIGHIZADEH et al., 2010](#)). A corrente de falta, próxima em magnitude à corrente normal de carga, torna os relés de sobrecorrente praticamente cegos a esse tipo de evento ([ALJOHANI; HABIBALLAH, 2020](#)).

Do ponto de vista elétrico, as FAIs apresentam três características marcantes que dificultam sua detecção e modelagem. A primeira é a não linearidade: o contato entre o condutor e o meio resistivo gera um arco elétrico intermitente, cujo comportamento não é descrito por uma resistência constante, mas por uma relação tensão-corrente não linear e variável no tempo ([ELKALASHY et al., 2007](#); [WANG; CUI, 2022](#)). A segunda é a assimetria da forma de onda de corrente: o arco conduz de forma diferente nos semiciclos positivo e negativo do ciclo da tensão, produzindo uma assimetria característica que é explorada por vários métodos de detecção ([NAM et al., 2001](#); [SHENG; ROVNYAK, 2004](#)). A terceira é o fenômeno de *buildup*: após o início da falta, a corrente cresce progressivamente ao longo dos primeiros ciclos, refletindo o aquecimento e a evolução do ponto de contato ([NAM et al., 2001](#)). Essas três características, combinadas, produzem assinaturas ricas em componentes harmônicas e inter-harmônicas que se tornaram a base dos principais métodos de detecção propostos na literatura ([MACEDO et al., 2015](#); [LIMA et al., 2018](#)).

A superfície de contato exerce influência direta sobre as propriedades elétricas da falta. Materiais como asfalto seco e concreto apresentam resistência muito elevada, produzindo correntes de falta próximas de zero; grama e solo úmido, por outro lado,

resultam em correntes ligeiramente maiores, porém ainda abaixo do limiar de atuação convencional (ALJOHANI; HABIBALLAH, 2020; SEDIGHIZADEH et al., 2010). Em razão dessa dependência, as assinaturas elétricas das FAIs variam consideravelmente conforme as condições ambientais e o tipo de material em contato com o condutor (ALJOHANI; HABIBALLAH, 2020).

Quando a superfície de contato é a vegetação, as FAIs assumem uma dimensão de risco ainda mais elevada. O contato entre um condutor energizado e galhos ou copas de árvores próximas cria um caminho de falta cujas propriedades elétricas dependem da espécie vegetal, do teor de umidade e do estágio de desenvolvimento do contato (OZANSOY; GOMES, 2020; YANG et al., 2025). Mesmo correntes de curtíssima duração e baixíssima magnitude são capazes de carbonizar o material vegetal e originar brasas incandescentes, configurando risco direto de ignição (GOMES et al., 2018; OZANSOY; GOMES, 2020). Estudos baseados em ensaios controlados mostram que o processo de ignição evolui em estágios sequenciais, são eles: contato inicial, expulsão de umidade e carbonização. Vale ressaltar que cada um possui assinaturas elétricas distintas na corrente de falta (OZANSOY; GOMES, 2020; OZANSOY, 2023). A elevada variabilidade entre espécies e condições ambientais torna a definição de limiares de detecção confiáveis um problema em aberto, o que motivou a criação de programas experimentais dedicados, como o *Vegetation Conduction Ignition Test Program*, desenvolvido pelo governo de Victoria, Austrália (Victorian Government, 2014; GOMES et al., 2018).

2.2 MÉTODOS DE DETECÇÃO DE FAIS

A dificuldade de detecção das FAIs motivou, ao longo de décadas, o desenvolvimento de uma ampla variedade de métodos. Como a corrente de falta não é suficiente para atuar as proteções convencionais, as abordagens propostas buscam explorar assinaturas elétricas indiretamente associadas ao fenômeno, como distorções harmônicas, componentes de alta frequência e padrões não lineares da forma de onda (SEDIGHIZADEH et al., 2010; ALJOHANI; HABIBALLAH, 2020). Apesar das décadas de pesquisa, ainda não existe uma solução padronizada e universalmente aceita para o problema (SEDIGHIZADEH et al., 2010).

Os trabalhos pioneiros remontam ao início da década de 1980. Aucoin e Russell (1982) foram os primeiros a propor sistematicamente o uso de componentes de alta frequência, na faixa de 2 a 10 kHz, da corrente de alimentador como assinatura de FAI, construindo um relé protótipo baseado em microcomputador testado em campo com resultados promissores. Alguns anos depois, Huang et al. (1988) compararam quatro algoritmos baseados em harmônicas de 2ª, 3ª e 5ª ordens em dados de faltas reais encenadas, estabelecendo uma referência metodológica para avaliação comparativa de

desempenho. [Aucoin e Jones \(1996\)](#) discutiram, além da eficácia técnica, as questões operacionais associadas à implantação de detectores de FAI em serviço, reconhecendo que a aceitação pela indústria dependia também de fatores não técnicos. Nesse período, Kim e Russell ([KIM; RUSSELL, 1989](#)) introduziram o uso de raciocínio indutivo e sistemas especialistas para classificação de FAIs, antecipando a transição para abordagens baseadas em aprendizado.

A partir dos anos 2000, métodos baseados em processamento de sinais passaram a dominar a literatura. [Sheng e Rovnyak \(2004\)](#) propuseram o uso de árvores de decisão treinadas com features harmônicas extraídas por simulação em EMTP, demonstrando que a combinação de múltiplas harmônicas aumenta a confiabilidade da detecção. [Macedo et al. \(2015\)](#) propuseram o uso de inter-harmônicos, gerados pela variação do comprimento do arco elétrico, como assinatura de detecção, com resultados validados em testes de campo em diferentes tipos de solo. [Santos et al. \(2017\)](#) desenvolveram um algoritmo baseado na Transformada Wavelet Discreta (DWT) capaz de identificar FAIs e indicar a área mais provável de ocorrência sem exigir sincronismo de dados ou conhecimento dos parâmetros da rede. Já [Lima et al. \(2018\)](#) utilizaram a Transformada de Fourier de Tempo Curto (STFT) para extrair magnitude e fase das principais harmônicas da corrente, sendo capaz de distinguir FAIs de outros distúrbios como chaveamento de capacitores e energização de alimentadores.

No campo das FAIs em vegetação, [Gomes et al. \(2018\)](#) demonstraram que o conteúdo de alta frequência dos sinais de tensão, associados ao arco elétrico intermitente típico desse tipo de falta, constitui uma assinatura discriminativa eficaz, validada com dados reais do programa experimental australiano. O classificador utilizado (*boosted decision trees*) alcançou alta sensibilidade tanto para faltas fase-terra quanto fase-fase de baixa magnitude. A revisão mais recente sobre FAIs em árvores, conduzida por [Yang et al. \(2025\)](#), organiza as contribuições da área em três eixos: modelagem, detecção e avaliação de risco de ignição e destaca a escassez de dados reais como o principal gargalo para o avanço da área. Abordagens baseadas em inteligência artificial, como SVM, redes neurais e XGBoost, têm sido progressivamente aplicadas ao problema, sendo discutidas com maior profundidade na Seção 2.4.

2.3 TÉCNICAS DE PROCESSAMENTO DE SINAIS

As faltas de alta impedância produzem sinais de corrente de baixa amplitude, não estacionários e fortemente contaminados pelo ruído de rede e pelas variações normais de carga. Essas características tornam insuficiente a análise direta no domínio do tempo ou o uso isolado de limiares de sobrecorrente, exigindo técnicas de processamento de sinais capazes de revelar padrões latentes nas formas de onda ([SEDIGHIZADEH et al., 2010](#);

[ALJOHANI; HABIBALLAH, 2020](#)). A escolha da técnica influencia diretamente quais atributos podem ser extraídos e, portanto, qual tipo de assinatura elétrica será utilizada na detecção ou classificação da falta.

A Transformada de Fourier Discreta (DFT) tornou-se uma das primeiras ferramentas amplamente empregadas na análise de FAIs, permitindo decompor o sinal de corrente em suas componentes de frequência. Para um sinal discreto $x[n]$ com N amostras, a DFT é definida como

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad k = 0, 1, \dots, N-1,$$

onde $X[k]$ representa a amplitude e fase da componente de frequência $f_k = kf_s/N$, sendo f_s a frequência de amostragem ([AUCOIN; RUSSELL, 1982](#); [HUANG et al., 1988](#)). Na prática, a DFT é computada de forma eficiente pelo algoritmo FFT (*Fast Fourier Transform*). Contudo, por ser uma transformada global, a DFT não captura variações temporais no conteúdo espectral, uma limitação crítica para sinais transientes como os das FAIs.

A Transformada de Fourier de Tempo Curto (STFT) supera parcialmente essa restrição ao multiplicar o sinal por uma função janela $w[n]$ deslizando antes de aplicar a DFT:

$$\text{STFT}\{x\}(m, k) = \sum_{n=-\infty}^{\infty} x[n] w[n-m] e^{-j\frac{2\pi}{N}kn}$$

obtendo assim uma representação tempo-frequência de resolução fixa. A escolha do tamanho da janela implica um compromisso: janelas longas oferecem boa resolução em frequência mas baixa resolução temporal, e vice-versa. [Lima et al. \(2018\)](#) demonstraram que a STFT permite extrair magnitude e fase das harmônicas de baixa ordem com robustez suficiente para distinguir FAIs de distúrbios comuns da rede, como chaveamento de bancos de capacitores e energização de alimentadores, inclusive quando aplicada a oscilografias reais.

A Transformada Wavelet Discreta (DWT) supera a limitação de resolução fixa da STFT ao decompor o sinal em sub-bandas de frequência através de filtros passa-alta $h[n]$ e passa-baixa $g[n]$ aplicados sucessivamente:

$$d_j[k] = \sum_n x[n] h[2k - n], \quad a_j[k] = \sum_n x[n] g[2k - n],$$

onde d_j são os coeficientes de detalhe (alta frequência) e a_j os coeficientes de aproximação (baixa frequência) no nível j de decomposição. Essa estrutura multirresolução permite analisar transientes de curta duração com alta resolução temporal e, ao mesmo tempo, capturar variações lentas com boa resolução em frequência (ELKALASHY et al., 2007). Santos et al. (2017) desenvolveram um algoritmo baseado em DWT que monitora componentes de alta e baixa frequência de tensão em múltiplos pontos do sistema, indicando a área mais provável de ocorrência da falta sem exigir sincronismo de dados ou conhecimento dos parâmetros do alimentador. No contexto das FAIs em vegetação, Elkalashy et al. (2007) mostraram que re-ignições do arco elétrico produzem transientes capturados com eficácia pelos coeficientes wavelet, reforçando a utilidade da DWT como ferramenta de extração de atributos nesse cenário.

Uma abordagem complementar e de grande relevância para a detecção de FAIs é o uso de **filtros rejeita-faixa harmônica** para isolar as componentes inter-harmônicas do sinal de corrente. A ideia central é que, durante uma FAI, a variação estocástica do comprimento do arco elétrico gera componentes de frequência que não são múltiplos inteiros da fundamental — as chamadas inter-harmônicas — enquanto, em condições normais, o espectro de corrente é dominado por harmônicas de ordem inteira e ruído de banda larga (MACEDO et al., 2015). Para revelar essas componentes, aplica-se ao sinal um banco de filtros que rejeita as frequências harmônicas conhecidas ($f_0, 2f_0, 3f_0, \dots$), preservando o resíduo inter-harmônico sobre o qual são calculadas as métricas de detecção.

Macedo et al. (2015) incorporaram esse banco de filtros a relés de religadores e seccionadores automáticos convencionais e validaram a metodologia em testes de campo em diferentes tipos de solo, com medições instantâneas da forma de onda de corrente durante a ocorrência de faltas reais. Os resultados demonstraram que as inter-harmônicas constituem uma assinatura robusta do arco intermitente das FAIs e que sua extração por filtros analíticos é compatível com a infraestrutura já existente de proteção automática. Essa característica torna o método particularmente atrativo do ponto de vista de implantação industrial, pois não exige hardware dedicado de alta frequência nem modificações estruturais no sistema de proteção (MACEDO et al., 2015).

2.4 ALGORITMOS DE INTELIGÊNCIA ARTIFICIAL

Os métodos baseados em processamento de sinais, embora eficazes na extração de assinaturas espectrais, dependem frequentemente da definição manual de limiares de decisão,

cuja calibração é sensível às condições operacionais e ao tipo de superfície de contato (ALJOHANI; HABIBALLAH, 2020; SEDIGHIZADEH et al., 2010). A variabilidade inerente das FAIs, especialmente aquelas envolvendo vegetação, cujas assinaturas dependem da espécie, umidade e estágio de ignição, torna atrativa a substituição de regras fixas por modelos capazes de aprender padrões diretamente dos dados. Esse contexto motivou a aplicação crescente de algoritmos de inteligência artificial (IA) ao problema de detecção e classificação de FAIs (ALJOHANI; HABIBALLAH, 2020).

Uma abordagem intermediária nessa evolução é representada pelos métodos com **limiar auto-adaptativo** (*self-adaptive threshold*). Ao contrário dos detectores com limiar fixo, esses métodos ajustam dinamicamente o critério de decisão em função de propriedades estatísticas do sinal monitorado — como média e desvio padrão calculados em janelas deslizantes — ou de condições operacionais da rede, como variações de carga e topologia do alimentador. A premissa é que, durante a operação normal, os indicadores extraídos do sinal apresentam comportamento estacionário que serve de referência; a detecção ocorre quando uma mudança estatisticamente significativa é observada em relação a essa linha de base (YU; KHAN, 1994; SEDIGHIZADEH et al., 2010).

Uma implementação concreta dessa ideia aplicada especificamente a FAIs é apresentada por (KIM; RUSSELL, 1993), que propõem um sistema de detecção baseado em um modelo de elemento adaptativo. O sistema combina múltiplos algoritmos de detecção operando em diferentes parâmetros de frequência e integra seus resultados por meio de pesos associados a cada par algoritmo-parâmetro, ajustados dinamicamente por uma fórmula elíptica de correção. Diferentemente de um limiar fixo global, o critério de decisão final emerge da combinação ponderada dos indicadores individuais, adaptando-se ao comportamento do sinal ao longo do tempo. Validado em exemplos de classificação falta/não-falta em alimentadores de distribuição, o método demonstrou bom desempenho especialmente em segurança contra identificações falsas (KIM; RUSSELL, 1993).

Entre os métodos supervisionados, as árvores de decisão foram pioneiras nessa transição. Sheng e Rovnyak (2004) demonstraram que uma árvore treinada com *features* harmônicas simuladas em EMTP era capaz de distinguir FAIs de chaveamentos e energizações com alta confiabilidade, ao custo de uma frequência de amostragem modesta (1920 Hz). O uso de *boosted decision trees* que é uma combinação de múltiplas árvores com atualização ponderada dos erros, foi adotado por Gomes et al. (2018) para classificação de VeHIFs a partir de conteúdo de alta frequência, obtendo alta sensibilidade em dados reais ruidosos. Métodos como SVM (*Support Vector Machine*) também foram aplicados ao problema, explorando a separabilidade das *features* no espaço transformado por núcleos não lineares (ALJOHANI; HABIBALLAH, 2020).

Algoritmos de ensemble mais avançados, como Random Forest e XGBoost, passaram a ser utilizados à medida que bases de dados reais tornaram-se disponíveis. [Ma et al. \(2020\)](#) aplicaram um modelo denominado *Hybrid Step XGBoost* a 188 registros de faltas reais do programa australiano PBSP, coletados em testes de campo com vegetação de copa superior. O modelo atingiu 98,17% de acurácia na classificação entre contatos seguros e perigosos entre vegetação e linhas aéreas, superando redes neurais profundas nos experimentos conduzidos. Esse resultado evidencia o potencial de métodos baseados em gradiente aplicados diretamente a dados de campo, sem recorrer a modelos simulados.

A disponibilidade pública do conjunto de dados VeHIF ([GOMES; OZANSOY, 2022](#)), originado do programa experimental do governo de Victoria, constitui um marco para a área, pois viabiliza a comparação objetiva de algoritmos sob as mesmas condições operacionais reais ([GOMES et al., 2018](#); [Victorian Government, 2014](#)). A ausência histórica de bases públicas com faltas reais em vegetação era apontada como um dos principais gargalos para o avanço da área ([GOMES; OZANSOY, 2022](#)). O presente trabalho se insere nesse contexto, propondo a extração e análise sistemática de atributos a partir desse conjunto de dados com vistas à construção de um classificador supervisionado.

3 METODOLOGIA

Este capítulo descreve as etapas metodológicas adotadas para caracterizar sinais de faltas de alta impedância em vegetação e avaliar a capacidade discriminativa dos atributos extraídos em um problema de classificação supervisionada. O desenvolvimento foi integralmente realizado em Python, utilizando as bibliotecas NumPy, SciPy, PyWavelets, scikit-learn e XGBoost.

3.1 BASE DE DADOS E ORIGEM DOS REGISTROS REAIS

O contexto que motivou a criação da base de dados utilizada neste trabalho remonta aos incêndios florestais de *Black Saturday*, ocorridos em fevereiro de 2009 no estado de Victoria, Austrália, que resultaram em 173 mortes e na destruição de mais de 2.000 residências ([Victorian Government, 2014](#)). Investigações posteriores indicaram que falhas em ativos elétricos, incluindo contatos entre condutores de distribuição e vegetação, figuraram entre as possíveis causas de alguns dos focos de incêndio.

A base de dados empregada neste trabalho é o VeHIF (*Vegetation High-Impedance Fault dataset*). Os registros foram obtidos a partir do *Vegetation Ignition Testing Program* (VITP), conduzido em uma rede de distribuição real de 22 kV, trifásica a três fios, no estado de Victoria, Austrália ([GOMES et al., 2018](#); [GOMES; OZANSOY, 2022](#)). Cada registro armazena sinais de corrente e tensão capturados simultaneamente por dois canais independentes:

- **Canal LF (*low frequency*)**: registra a componente fundamental da forma de onda de corrente, sendo adequado para análise de harmônicas, inter-harmônicas e estatísticas da forma de onda no entorno dos 60 Hz.
- **Canal HF (*high frequency*)**: registra as componentes espectrais de alta frequência associadas ao arco elétrico, com foco na faixa de 2 a 10 kHz identificada na literatura como assinatura característica de FAIs em vegetação ([AUCOIN; RUSSELL, 1982](#); [GOMES et al., 2018](#)).

O conjunto disponibilizado por [Gomes e Ozansoy \(2022\)](#) no formato HDF5 (*Hierarchical Data Format version 5*) reúne mais de 900 registros, cobrindo múltiplas espécies vegetais nativas australianas, diferentes níveis de umidade e configurações variadas de contato. O acesso ao *dataset* é realizado via biblioteca `h5py` em Python. Cada arquivo

contém os *arrays* de sinal dos canais LF e HF, a frequência de amostragem correspondente e metadados do experimento (espécie vegetal, condição de umidade e rótulo de evento).

A inspeção inicial da estrutura dos arquivos HDF5 constitui a primeira etapa prática do trabalho e é necessária para confirmar os nomes dos *datasets* internos, as taxas de amostragem efetivas e os metadados disponíveis antes de implementar o módulo de carregamento de dados.

3.2 DEFINIÇÃO DO PROBLEMA E DAS CLASSES

O problema é formulado como uma tarefa de **classificação supervisionada binária**. O objetivo é treinar modelos capazes de distinguir, a partir de atributos extraídos dos sinais de corrente, registros de contato de vegetação com risco de ignição daqueles sem risco ou correspondentes à operação normal da rede.

A definição das classes baseia-se no critério de risco de ignição estabelecido na literatura (OZANSOY; GOMES, 2020; GOMES et al., 2018). Conforme descrito em Ozansoy (2023), o processo de ignição em contatos de vegetação evolui em estágios sequenciais — contato inicial, expulsão de umidade e carbonização —, cada um com assinaturas elétricas distintas nos sinais de corrente. Registros nos quais o contato evoluiu até o estágio de carbonização ou produziu correntes de arco de amplitude e duração suficientes para causar ignição são classificados como **perigosos**; os demais, incluindo contatos de baixa energia e registros de operação sem falta, são classificados como **seguros**.

A divisão concreta das classes será determinada durante a análise exploratória, com base na estrutura de rótulos presente nos metadados do VeHIF e nos critérios operacionais descritos em Ozansoy e Gomes (2020). Caso a distribuição entre classes seja desequilibrada, esse aspecto será considerado tanto na escolha das métricas de avaliação (Seção 3.7) quanto nos parâmetros de ponderação dos classificadores.

3.3 PRÉ-PROCESSAMENTO E PREPARAÇÃO DOS SINAIS

Antes da extração de atributos, cada sinal de corrente é submetido a uma cadeia de pré-processamento com o objetivo de remover artefatos e garantir a comparabilidade entre registros de condições distintas. As etapas aplicadas são as seguintes:

1. **Remoção de componente DC:** subtração da média do sinal para eliminar o *offset* de corrente contínua residual.
2. **Filtragem passa-faixa:** aplicação de um filtro Butterworth de fase zero para isolar a banda de frequência de interesse em cada canal. Para o canal LF, a banda é

centrada na componente fundamental de 60 Hz; para o canal HF, a faixa de 2 a 10 kHz é preservada. Os parâmetros exatos do filtro (ordem e frequências de corte) são ajustados com base na análise espectral conduzida na etapa exploratória.

3. **Segmentação por ciclos:** o sinal filtrado é dividido em janelas temporais de comprimento fixo, correspondendo a N_c ciclos da frequência fundamental. O comprimento de cada janela em amostras é dado por

$$L = N_c \cdot \left\lfloor \frac{f_s}{f_0} \right\rfloor, \quad (1)$$

onde f_s é a frequência de amostragem e $f_0 = 60$ Hz. O valor de N_c é escolhido em função da duração típica dos registros e do compromisso entre resolução temporal e robustez estatística dos atributos.

4. **Normalização:** cada janela é normalizada pelo valor de pico (intervalo $[-1, 1]$) para atenuar diferenças de amplitude entre registros de diferentes condições de contato.

Registros com valores ausentes, saturação de sinal ou duração inferior a dois ciclos são identificados e descartados durante a etapa de análise exploratória. Todo o pré-processamento é implementado no módulo `src/preprocessing.py`.

3.4 EXTRAÇÃO DE ATRIBUTOS E CARACTERIZAÇÃO DAS FAIS EM VEGETAÇÃO

Os atributos são extraídos de cada janela de sinal nos domínios do tempo, da frequência e tempo-frequência. A motivação para cada grupo de atributos está fundamentada nas características elétricas das FAIs em vegetação discutidas no Capítulo 2.

3.4.1 Atributos no domínio do tempo

Os atributos temporais capturam características estatísticas e morfológicas da forma de onda, exploradas desde os primeiros trabalhos de detecção de FAIs (NAM et al., 2001; SHENG; ROVNYAK, 2004):

- **Energia:** soma dos quadrados das amostras da janela,

$$E = \sum_{n=0}^{L-1} x^2[n]. \quad (2)$$

- **Assimetria (*skewness*):** medida de assimetria da distribuição de amplitude,

$$\gamma_1 = \frac{1}{L} \sum_{n=0}^{L-1} \left(\frac{x[n] - \mu}{\sigma} \right)^3, \quad (3)$$

onde μ e σ são, respectivamente, a média e o desvio padrão da janela. Valores elevados de γ_1 refletem a condução assimétrica do arco entre semiciclos positivo e negativo, característica marcante das FAIs (NAM et al., 2001).

- **Curtose (*kurtosis*)**: medida de impulsividade da distribuição,

$$\kappa = \frac{1}{L} \sum_{n=0}^{L-1} \left(\frac{x[n] - \mu}{\sigma} \right)^4 - 3. \quad (4)$$

Valores elevados indicam transientes impulsivos característicos de re-ignições do arco elétrico.

- **Buildup**: razão entre a energia média dos ciclos subsequentes e a energia do primeiro ciclo da janela,

$$B = \frac{E_{\text{resto}}}{E_{1 \text{ ciclo}}}, \quad (5)$$

quantificando o crescimento progressivo de corrente descrito em Nam et al. (2001) como uma das assinaturas mais características das FAIs em vegetação.

- **Rugosidade**: variância da derivada discreta do sinal,

$$R = \text{Var}(x[n] - x[n - 1]), \quad (6)$$

capturando flutuações locais rápidas associadas à instabilidade do arco.

3.4.2 Atributos no domínio da frequência

Os atributos espectrais são calculados a partir da FFT (*Fast Fourier Transform*) de cada janela de sinal, conforme definido na Seção 2.3:

- **Amplitudes harmônicas**: amplitude espectral de pico em torno das frequências $k \cdot f_0$, para $k = 1, 2, \dots, 5$, totalizando cinco atributos. O conteúdo harmônico de baixa ordem é explorado desde Aucoin e Russell (1982) e Huang et al. (1988) como assinatura de FAIs.
- **Conteúdo inter-harmônico**: razão entre a energia espectral fora das bandas harmônicas e a energia total do espectro,

$$C_{\text{IH}} = \frac{\sum_{k \notin \mathcal{H}} |X[k]|^2}{\sum_k |X[k]|^2}, \quad (7)$$

onde $\mathcal{H}$ representa o conjunto de índices de frequência nas vizinhanças das harmônicas de f_0 . Esse atributo captura a contribuição das inter-harmônicas geradas pela variação do comprimento do arco (MACEDO et al., 2015).

- **Energia de alta frequência:** razão entre a energia espectral na faixa de 2 a 10 kHz e a energia total do espectro. Este atributo é especialmente relevante para o canal HF e constitui a base do método proposto por [Gomes et al. \(2018\)](#) para detecção de VeHIFs.

3.4.3 Atributos no domínio tempo-frequência

Dois métodos de análise tempo-frequência são empregados, com base na revisão conduzida na Seção 2.3:

- **Energia por nível DWT:** o sinal é decomposto pela Transformada Wavelet Discreta utilizando a wavelet de Daubechies de ordem 4 (**db4**) em $J = 5$ níveis de decomposição. Os coeficientes de detalhe $d_j[k]$ de cada nível j capturam sub-bandas de frequência distintas, com resolução temporal inversamente proporcional ao nível ([ELKALASHY et al., 2007](#); [SANTOS et al., 2017](#)). O atributo extraído é a energia relativa de detalhe em cada nível,

$$E_j^{\text{DWT}} = \frac{\sum_k d_j^2[k]}{\sum_n x^2[n]}, \quad j = 1, \dots, J, \quad (8)$$

totalizando $J = 5$ atributos por janela.

- **Energia HF média via STFT:** a STFT é calculada sobre o sinal com janela de comprimento M amostras, e para cada quadro temporal m computa-se a fração de energia na faixa de 2 a 10 kHz. O atributo final é a média desta fração sobre todos os T quadros,

$$E_{\text{HF}}^{\text{STFT}} = \frac{1}{T} \sum_{m=1}^T \frac{\sum_{k: f_k \in [2, 10] \text{ kHz}} |Z(m, k)|^2}{\sum_k |Z(m, k)|^2}, \quad (9)$$

onde $Z(m, k)$ denota o espectrograma calculado pela STFT ([LIMA et al., 2018](#)).

O vetor de atributos resultante da aplicação de todos os extratores a uma janela de sinal de um único canal contém $5 + 7 + 6 = 18$ atributos. Quando os dois canais LF e HF são considerados conjuntamente, o vetor completo possui 36 atributos.

3.5 SELEÇÃO DE ATRIBUTOS

A seleção de atributos tem duplo propósito: reduzir a dimensionalidade do vetor de entrada dos classificadores e identificar quais atributos são mais informativos para o problema em questão, contribuindo para a interpretabilidade dos resultados. Dois métodos complementares são empregados:

- **F-score ANOVA:** teste univariado que avalia se a distribuição de cada atributo difere significativamente entre as classes, por meio da razão entre a variância inter-classe e a variância intra-classe.
- **Importância por floresta aleatória:** um classificador Random Forest é treinado e a redução média de impureza de Gini associada a cada atributo é utilizada como medida de importância global (YANG et al., 2025). Esse método captura interações entre atributos, o que o torna complementar ao F-score ANOVA de natureza univariada.

Os resultados de ambas as abordagens serão comparados para identificar consensos e discrepâncias. O número k de atributos selecionados será determinado pela análise do desempenho dos classificadores em função de k (diagrama de cotovelo), equilibrando desempenho e parcimônia do modelo.

3.6 CLASSIFICADORES SUPERVISIONADOS

Quatro algoritmos de classificação supervisionada são avaliados, abrangendo diferentes paradigmas de aprendizado e graus de interpretabilidade, conforme motivado na Seção 2.4:

1. **Árvore de Decisão** (*Decision Tree*, DT): estrutura hierárquica de partições binárias no espaço de atributos, com alta interpretabilidade. Classifica uma instância percorrendo o grafo da raiz até um nó folha, aplicando limiares sobre atributos individuais. Referência consolidada no contexto de FAIs desde Sheng e Rovnyak (2004).
2. **Máquina de Vetores de Suporte** (*Support Vector Machine*, SVM): classificador de margem máxima com *kernel* RBF (*Radial Basis Function*) para captura de separações não lineares entre classes (ALJOHANI; HABIBALLAH, 2020). Os atributos são normalizados com *z-score* antes da aplicação do modelo.
3. **XGBoost** (*eXtreme Gradient Boosting*): método *ensemble* baseado em gradiente que combina sequencialmente árvores de decisão rasas, cada uma corrigindo os erros residuais da anterior. Atingiu 98,17% de acurácia em dados reais do PBSP no trabalho de Ma et al. (2020).
4. **Rede Neural Artificial** (*Multilayer Perceptron*, MLP): rede com duas camadas ocultas (128 e 64 neurônios, ativação ReLU), treinada com parada precoce (*early stopping*) para evitar sobreajuste. Normalização dos atributos aplicada antes do treinamento.

Todos os classificadores são implementados via `scikit-learn` e `xgboost` com hiperparâmetros padrão como ponto de partida, permitindo uma avaliação inicial comparável. Ajuste fino via busca em grade poderá ser aplicado ao melhor modelo identificado nos experimentos preliminares.

3.7 MÉTRICAS DE AVALIAÇÃO E ANÁLISE DE DESEMPENHO

O desempenho dos classificadores é avaliado por meio de validação cruzada estratificada com $k = 5$ partições. A estratificação garante que a proporção entre as classes seja preservada em cada partição, o que é especialmente relevante em conjuntos com distribuição desequilibrada.

As métricas reportadas para cada dobra, e como médias com desvio padrão, são:

- **Acurácia:** proporção de classificações corretas sobre o total de instâncias,

$$Ac = \frac{VP + VN}{VP + VN + FP + FN}, \quad (10)$$

onde VP , VN , FP e FN denotam, respectivamente, verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

- **Precisão:** proporção de instâncias classificadas como positivas que são efetivamente positivas,

$$P = \frac{VP}{VP + FP}. \quad (11)$$

- **Recall** (sensibilidade): proporção de instâncias positivas reais que são corretamente identificadas,

$$R = \frac{VP}{VP + FN}. \quad (12)$$

No contexto de detecção de faltas, o *recall* possui especial relevância operacional: faltas não detectadas (falsos negativos) correspondem a eventos de risco de ignição não identificados.

- **F₁-score:** média harmônica entre precisão e *recall*,

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R}, \quad (13)$$

que equilibra o impacto de falsos positivos e falsos negativos em uma única métrica agregada.

Os resultados finais são apresentados em tabelas comparativas entre os quatro classificadores, considerando cada configuração de atributos testada: canal LF, canal HF,

conjunto completo de 36 atributos e subconjunto de k atributos selecionados. A análise visa identificar qual combinação de atributos e classificador oferece o melhor compromisso entre desempenho preditivo e interpretabilidade para o problema de detecção de VeHIFs.

REFERÊNCIAS

- ALJOHANI, A. S.; HABIBALLAH, I. High-impedance fault diagnosis: A review. **Energies**, v. 13, n. 23, p. 6447, 2020.
- AUCOIN, B. M.; JONES, R. H. High impedance fault detection implementation issues. **IEEE Transactions on Power Delivery**, 1996.
- AUCOIN, B. M.; RUSSELL, B. Distribution high impedance fault detection utilizing high frequency current components. **IEEE Transactions on Power Apparatus and Systems**, 1982.
- ELKALASHY, N.; LEHTONEN, M.; DARWISH, H. A.; IZZULARAB, M.; TAALAB, A. Modeling and experimental verification of high impedance arcing fault in medium voltage networks. **IEEE Transactions on Dielectrics and Electrical Insulation**, 2007.
- GOMES, D. P.; OZANSOY, C. Vehif: An accessible vegetation high-impedance fault data set format. **IEEE Transactions on Power Delivery**, 2022.
- GOMES, D. P.; OZANSOY, C.; ULHAQ, A. High-sensitivity vegetation high-impedance fault detection based on signal's high-frequency contents. **IEEE Transactions on Power Delivery**, 2018.
- HUANG, C.; CHU, H.; CHEN, M.-T. Algorithm comparison for high impedance fault detection based on staged fault test. **IEEE Transactions on Power Delivery**, 1988.
- International Energy Agency. **Electricity security matters more than ever**. 2020. Acesso em: 17 abr. 2026. Disponível em: <<https://www.iea.org/reports/power-systems-in-transition/electricity-security-matters-more-than-ever>>.
- KIM, C. J.; RUSSELL, B. Classification of faults and switching events by inductive reasoning and expert system methodology. **IEEE Power Engineering Review**, 1989.
- KIM, C. J.; RUSSELL, B. High-impedance fault detection system using an adaptive element model. **IEE Proceedings C – Generation, Transmission and Distribution**, 1993.
- LIMA, É. M.; JUNQUEIRA, C. M. S.; BRITO, N.; SOUZA, B. A.; COELHO, R. D. A.; MEDEIROS, H. G. M. S. High impedance fault detection method based on the short-time fourier transform. **IET Generation, Transmission & Distribution**, 2018.
- MA, J.; CHENG, J. C. P.; JIANG, F.; GAN, V.; WANG, M.; ZHAI, C. Real-time detection of wildfire risk caused by powerline vegetation faults using advanced machine learning techniques. **Advanced Engineering Informatics**, v. 46, 2020.
- MACEDO, J. R.; RESENDE, J.; BISSOCHI, C.; CARVALHO, D. P.; CASTRO, F. Proposition of an interharmonic-based methodology for high-impedance fault detection in distribution systems. **IET Generation, Transmission & Distribution**, 2015.
- NAM, S.; PARK, J.; KANG, Y. C.; KIM, T. A modeling method of a high impedance fault in a distribution system using two series time-varying resistances in emtp. In: **IEEE Power Engineering Society Summer Meeting**. [S.l.: s.n.], 2001.

OZANSOY, C. Vehif current arcing, volatility and vegetation ignition development: An emd based volatility analysis for earth-fault classification. **Engineering Science and Technology, an International Journal**, 2023.

OZANSOY, C.; GOMES, D. P. Electrical and physical characterization of earth faults for diverse bush species. **Engineering Science and Technology, an International Journal**, 2020.

SANTOS, W. C.; LOPES, F. V.; BRITO, N.; SOUZA, B. A. High-impedance fault identification on distribution networks. **IEEE Transactions on Power Delivery**, 2017.

SEDIGHIZADEH, M.; REZAZADEH, A.; ELKALASHY, N. Approaches in high impedance fault detection – a chronological review. **Advances in Electrical and Computer Engineering**, 2010.

SHENG, Y.; ROVNYAK, S. M. Decision tree-based methodology for high impedance fault detection. **IEEE Transactions on Power Delivery**, 2004.

Victorian Government. **Powerline Bushfire Safety Program: Vegetation Conduction Ignition Test Report**. 2014. Acesso em: 08 abr. 2026. Disponível em: <<https://discover.data.vic.gov.au/dataset/powerline-bushfire-safety-program-vegetation-conduction-ignition-test-report>>.

WANG, B.; CUI, X. Nonlinear modeling analysis and arc high-impedance faults detection in active distribution networks with neutral grounding via petersen coil. **IEEE Transactions on Smart Grid**, 2022.

WESTER, C. High impedance fault detection on distribution systems. In: **Rural Electric Power Conference**. [S.l.: s.n.], 1998.

YANG, C.; ZHANG, W.; TANG, R.; XIAO, X. Tree-related high-impedance fault in distribution systems: Modeling, detection, and ignition risk assessment. **Energies**, 2025.

YU, D. C.; KHAN, S. H. An adaptive high and low impedance fault detection method. **IEEE Transactions on Power Delivery**, v. 9, n. 4, p. 1812–1821, 1994.